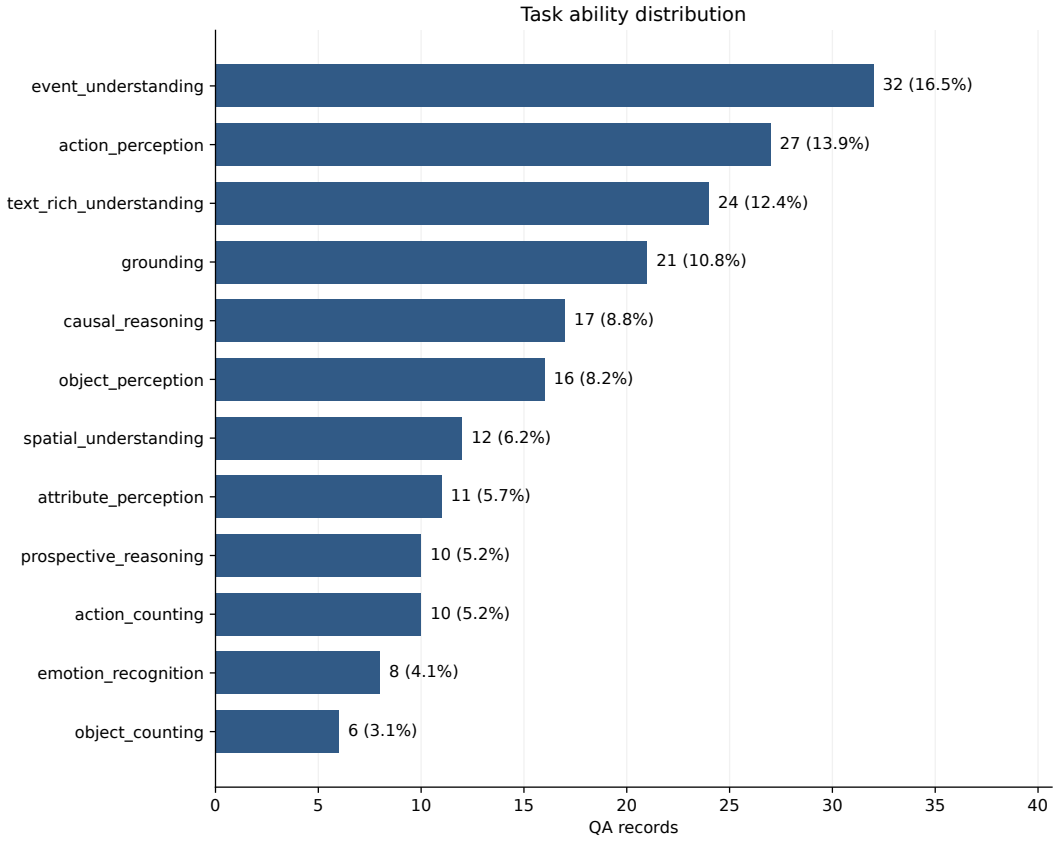
OmniDuplex 合并数据集统计（2026-10-14）

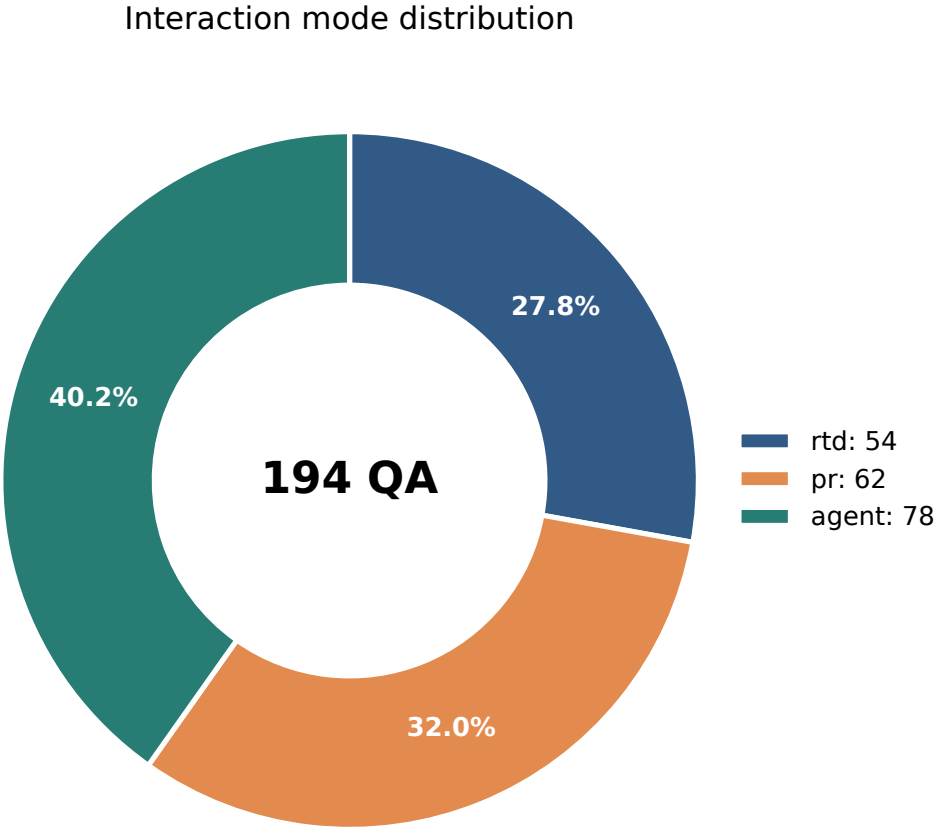
统计对象是完整的 194 条 QA 合并数据。下列图表均以**全部 194 条**为范围；视频长度按 51 个不重复视频统计。数据来源及 SHA-256 见同目录的 `manifest.json`。

任务类型

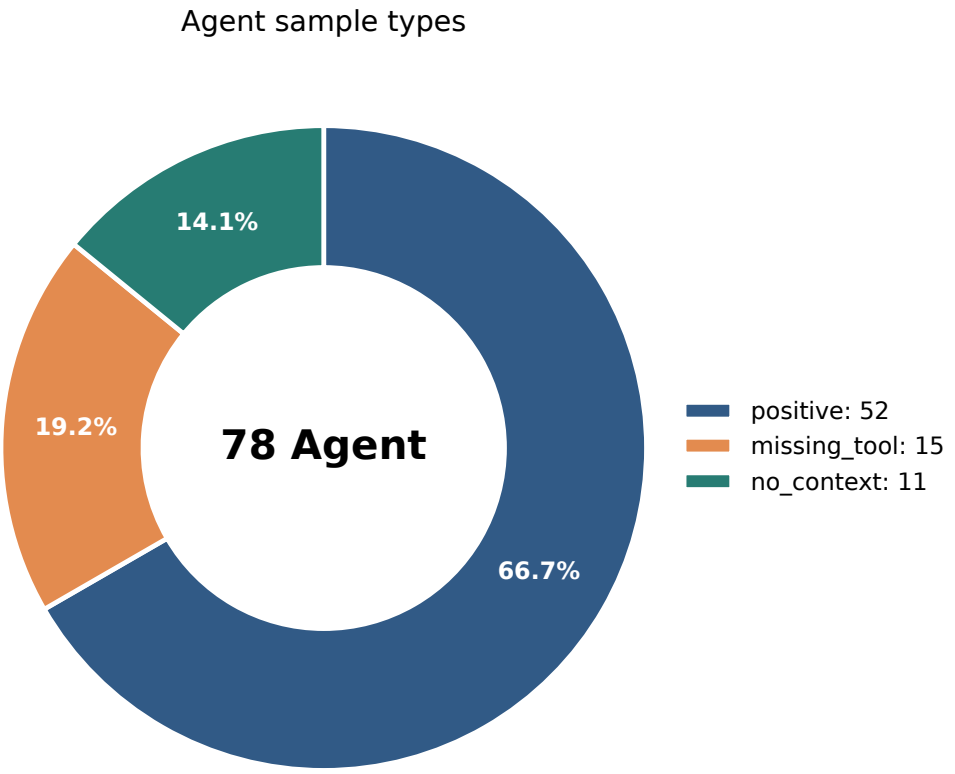


任务	数量	任务	数量
event_understanding	32	action_perception	27
text_rich_understanding	24	grounding	21
causal_reasoning	17	object_perception	16
spatial_understanding	12	attribute_perception	11
action_counting	10	prospective_reasoning	10
emotion_recognition	8	object_counting	6

交互类型与 Agent 子类型

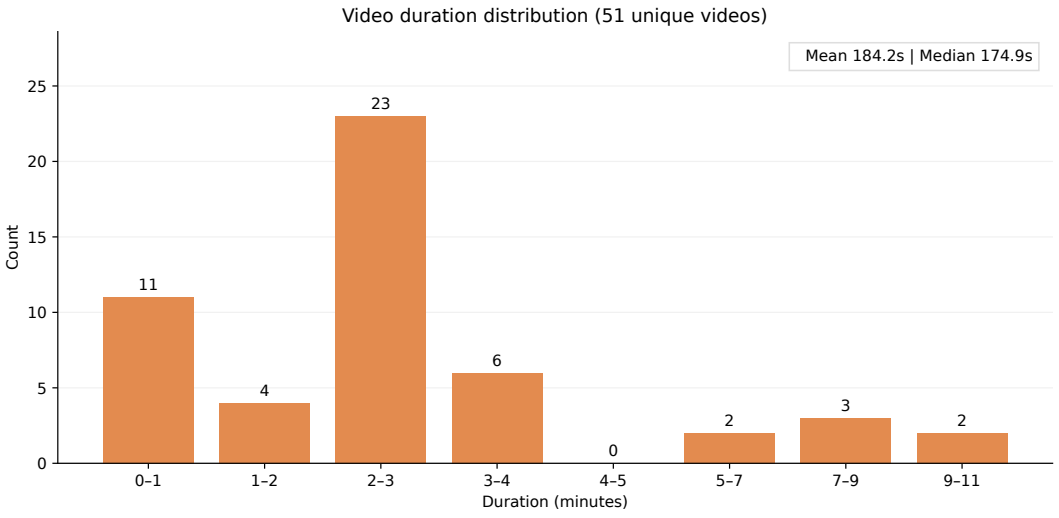


交互类型为 Agent **78 条（40.2%）**、PR **62 条（32.0%）**、RTD **54 条（27.8%）**。



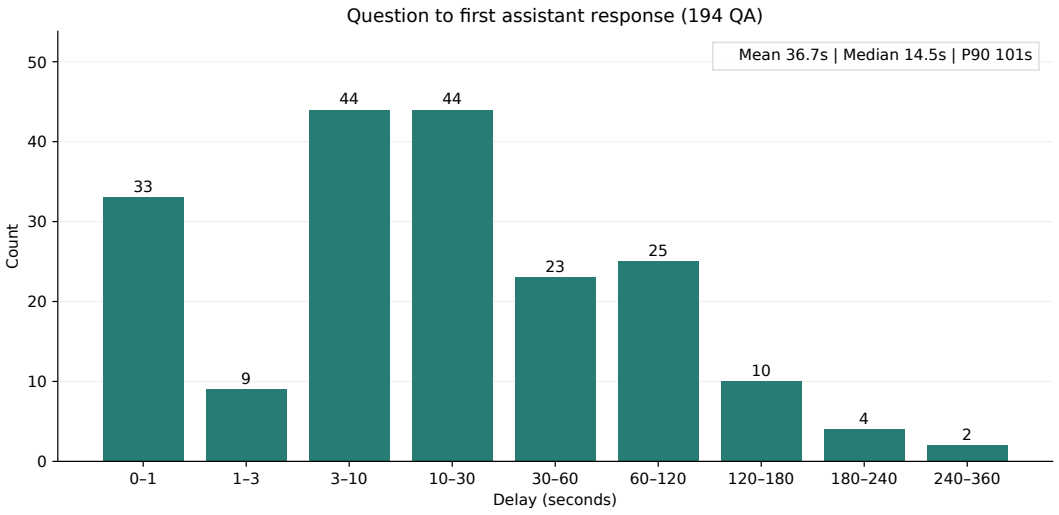
78 条 Agent 数据中，positive 52 条，missing_tool 15 条，no_context 11 条。

视频长度



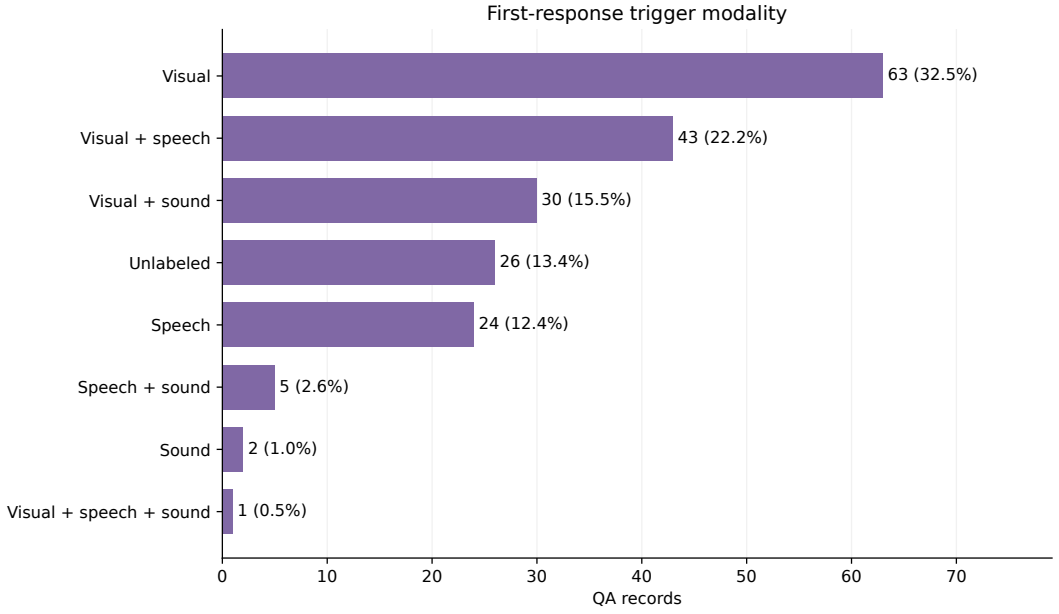
51 个不重复视频的平均长度为 **184.17 秒**，中位数 **174.87 秒**，范围 **12.92–599.55 秒**。长度取 `generation_context.duration_seconds`，同一视频只计一次。

提问到首次回复的延时



194 条 QA 的首个模型回复相对 `question_time` 的延时平均 **36.70 秒**，中位数 **14.5 秒**，P90 **101 秒**。按交互类型，RTD 的平均/中位数为 **24.81/5.5 秒**，PR 为 **49.44/26 秒**，Agent 为 **34.81/16 秒**。这里使用标注中的 `trigger_time − question_time`，**不是模型实际推理耗时**；Agent 工具返回不算模型回复。

首次回复的触发模态



图中把 `speech+visual` 与 `visual+speech` 等顺序不同但组成相同的标签合并。纯视觉 63 条、视觉 + 语音 43 条、视觉 + 声音 30 条、纯语音 24 条、语音 + 声音 5 条、纯声音 2 条、视觉 + 语音 + 声音 1 条；另有 26 条首次回复未标注触发模态。