AOI-Dataset 训练数据统计

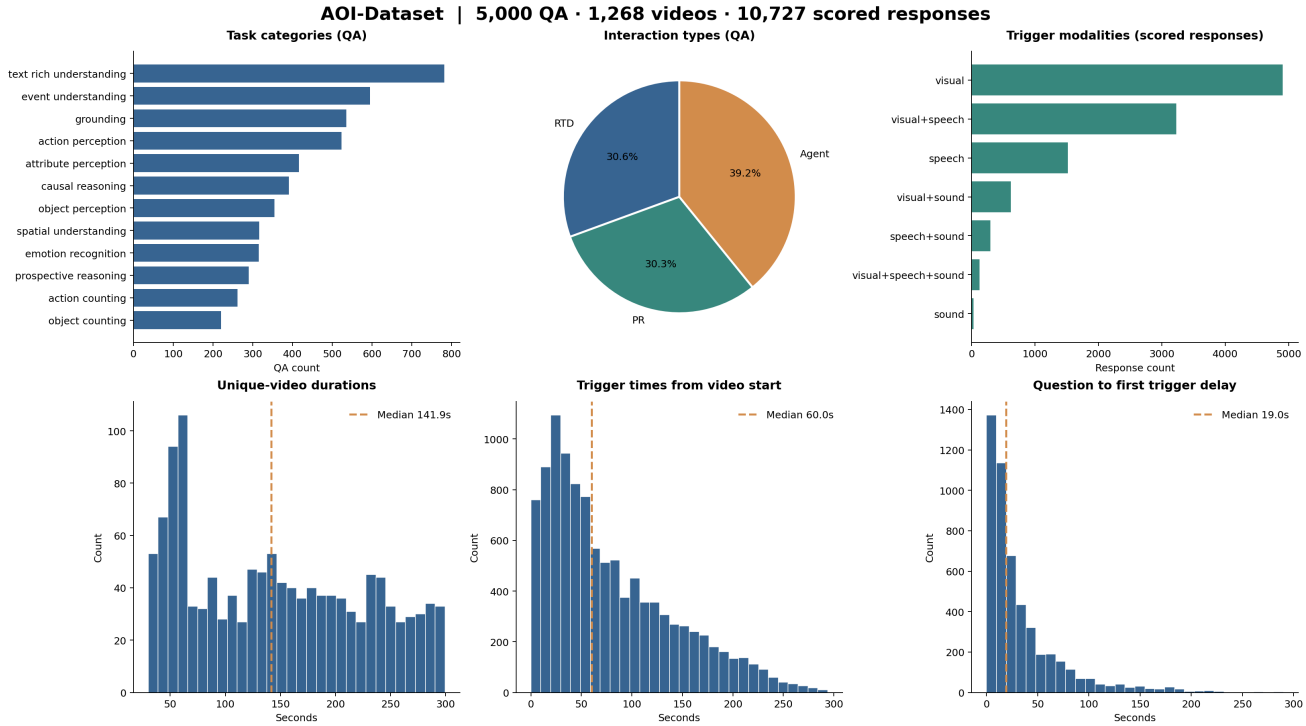
统计时间：2026-10-24T01:26:27.630763+00:00。

数据集：overji/AOI-Dataset，视频来源全部为 FineVideo。 本次本地来源：`/remote-home/yushengliao/speech/jimodels/datasets/AOI-Dataset`。统计过程只读，不改写数据、不加载模型、不启动训练。

总览

指标	数值
QA	5,000
唯一视频	1,268
平均 QA / 视频	3.94
平均不同任务类别 / 视频	2.41
原始 response 记录	14,805
可评分 response	10,727
唯一视频总时长	51.74 小时
视频文件总大小	9.57 GiB
Agent 负样本	0

视频总时长按唯一视频计数；QA 与 response 均不是独立视频数。原始 response 包含工具结果及后续完成回复。 按当前 benchmark 的 reference_windows 口径排除 4,078 条非触发记录后，剩余 10,727 条用于后续 response 模态、触发时间、窗口及延时统计。 Agent 只计含 agent_call/task_start 的 assistant 触发回复，不将模拟工具结果或工具返回后的完成回复算作触发。



SVG 图表

交互类型

交互类型	QA	占比
RTD	1,529	30.58%
PR	1,513	30.26%
AGENT	1,958	39.16%

任务类别 × 交互类型

任务类别	RTD	PR	Agent	总计	占比
action_counting	78	73	111	262	5.24%
action_perception	155	156	212	523	10.46%
attribute_perception	129	123	164	416	8.32%
causal_reasoning	135	119	137	391	7.82%
emotion_recognition	97	94	124	315	6.30%
event_understanding	189	187	219	595	11.90%
grounding	159	169	207	535	10.70%

任务类别	RTD	PR	Agent	总计	占比
object_counting	64	67	89	220	4.40%
object_perception	115	98	142	355	7.10%
prospective_reasoning	98	78	114	290	5.80%
spatial_understanding	90	105	121	316	6.32%
text_rich_understanding	220	244	318	782	15.64%

触发模态：按可评分 response

类别	数量	占比
visual	4,905	45.73%
visual+speech	3,229	30.10%
speech	1,520	14.17%
visual+sound	621	5.79%
speech+sound	298	2.78%
visual+speech+sound	125	1.17%
sound	29	0.27%

speech 指语言语音，sound 指非语言声音；组合标签表示同一触发依赖的证据模态。

QA 模态：该 QA 全部触发模态的并集

类别	数量	占比
visual	2,033	40.66%
visual+speech	1,643	32.86%
speech	676	13.52%
visual+sound	283	5.66%
visual+speech+sound	217	4.34%
speech+sound	134	2.68%
sound	14	0.28%

QA 采用互斥的模态并集统计；某个 QA 的不同回复可分别为 visual 与 speech，其 QA 并集会计为 visual+speech。

生成采样偏好 preferred_modality

类别	数量	占比
audio	3,471	69.42%
vision	1,529	30.58%

preferred_modality 是生成时的采样偏好，不等于实际 trigger_type，不能将 audio 偏好占比当成纯音频 QA 占比。

视觉依赖 vision_dependency

类别	数量	占比
required	3,376	67.52%
helpful	1,393	27.86%
none	231	4.62%

音频依赖 audio_dependency

类别	数量	占比
helpful	1,882	37.64%
required	1,793	35.86%
none	1,325	26.50%

视频时长、触发时间与交互延时

指标（秒）	N	均值	中位数	P90	P95	最小	最大
唯一视频时长	1,268	146.91	141.91	263.26	283.12	30.00	299.72
问题输入时间	5,000	23.23	0.00	80.00	120.00	0.00	251.00
首次 trigger（距视频起点）	5,000	56.11	39.00	134.00	168.05	0.00	290.00
末次 trigger（距视频起点）	5,000	86.87	67.00	189.00	219.00	0.00	294.00
全部 trigger（距视频起点）	10,727	78.65	60.00	173.00	205.00	0.00	294.00

指标（秒）	N	均值	中位数	P90	P95	最小	最大
question → 首次 trigger	5,000	32.89	19.00	80.00	111.00	0.00	290.00
question → 每个 trigger	10,727	55.78	36.00	138.00	176.00	0.00	291.00
回复窗口宽度	10,727	5.01	4.00	9.00	12.00	0.00	165.00

延时指参考标注的 `trigger_time - question_time`，不是模型推理 wall time，也不是工具执行耗时；窗口宽度为 window_end − window_start。分位数采用线性插值。

每视频 QA 数量分布（视频为分母）

类别	数量	占比
4	329	25.95%
3	298	23.50%
2	190	14.98%
5	156	12.30%
6	140	11.04%
1	65	5.13%
7	45	3.55%
8	28	2.21%
10	5	0.39%
12	5	0.39%
9	4	0.32%
13	2	0.16%
14	1	0.08%

Agent 必需工具

类别	数量	占比
web_search	965	49.28%
note_write	912	46.58%
product_search	181	9.24%

类别	数量	占比
note_search	128	6.54%
shopping_list_update	54	2.76%
calculator	50	2.55%
todo_create	39	1.99%
weather_query	33	1.69%
calendar_query	15	0.77%
document_search	14	0.72%
route_query	9	0.46%
notification_send	8	0.41%
shopping_list_query	8	0.41%
calendar_create	5	0.26%
order_query	5	0.26%
knowledge_search	4	0.20%
itinerary_query	3	0.15%
budget_query	1	0.05%
history_query	1	0.05%
meeting_draft	1	0.05%
statistics_compute	1	0.05%

同一条 Agent QA 可要求多个工具，因此必需工具占比之和可能超过 100%。

当前训练配置下的时间条件覆盖

每条 QA 取最早一个可评分 response，保留从视频第 0 秒开始的完整前缀；目标发声秒同时受问题输入、证据 available_time、trigger confirmed_time、窗口和整数秒因果约束。 下表调用当前 train.first_record 逻辑，仅在内存中改变候选前缀上限做统计，没有修改训练配置。

前缀上限（秒）	合格 QA	占全部 QA	覆盖视频	RTD	PR	Agent
32	2,190	43.80%	930	848	427	915
64	3,382	67.64%	1147	1163	832	1387
128	4,449	88.98%	1245	1415	1234	1800

前缀上限（秒）	合格 QA	占全部 QA	覆盖视频	RTD	PR	Agent
256	4,992	99.84%	1267	1529	1505	1958
512	5,000	100.00%	1268	1529	1513	1958

这些是时间与媒体存在性条件下的候选数，不是编码成功数。 尚未逐样本编码检查 `max_sequence_tokens=8192`，更长前缀仍可能超 token 上限或显存。 默认 32 秒排除原因：`{"prefix_too_long": 2810}`。默认 prepare 的 --max-samples 仍为 12，不会自动使用全部 5,000 条。

数据完整性检查


```
{
  "metadata_video_count_matches": true,
  "metadata_qa_count_matches": true,
  "missing_video_files": 0,
  "extra_metadata": 0,
  "metadata_qa_count_mismatches": 0,
  "duration_mismatches": 0,
  "invalid_scored_windows": 42,
  "triggers_before_question": 0,
  "agent_negative_indices": 0,
  "out_of_video_triggers": 0
}
```


上表的列表型检查项以问题记录数量展示，完整索引在 JSON 中。窗口边界问题详见 CSV。 本次有 42 条可评分窗口未通过严格边界检查；其中仅窗口末尾越过视频时长且其他时序合法的有 42 条，最大越界 0.491000 秒。未修改或裁剪原始窗口。

已检查全部引用文件存在、metadata 计数、每视频 QA 数、时长一致性、可评分窗口边界及问题/触发时序。未逐个重新解码视频，未校验媒体内容哈希；未执行语义正确性或感知证据审核。 当前发布 metadata 没有视频体裁分类字段，报告不根据标题推测体裁。metadata 的 source_qa 和生成机路径属于来源记录，不是当前训练所依赖的可用路径。

版本与复现

- all_qa.json SHA-256：`3809db9b78f1f3cadee16cafc13b7fd0133ee17ee84e451428ac87f376014d30`
- video_metadata.json SHA-256：`82a5e21b30641be1b3dccf68a28d1981a7eed86cb508a24bffdac609eaf75826`
- 完整数值：aoi_dataset_statistics.json
- 逐视频统计：aoi_dataset_video_statistics.csv

在仓库根目录执行；--plots 仅需要现有 matplotlib，不加载模型：

```
python train/scripts/dataset_statistics.py --plots
# 自定义下载目录：
python train/scripts/dataset_statistics.py --dataset-dir /path/to/AOI-Datase
```